

MIT液态神经网络团队 LFM2-VL 系列模型详解 —— 面向边缘设备的高效视觉语言理解

Original hitower TowerFlow 2025年12月15日 17:00

”液态神经网络“这个专业术语，AI算法同学在24-25年应该多少都会听到过。但是否仅限于自媒体上昙花一现的博客推送？本文将对MIT LFM(Liquid Foundation Model)团队25年新推出的LFM2系模型中的多模态版本LFM2-VL进行解析。

LFM2-VL是2025年度众多VLM理解模型中，笔者最欣赏的一个系列。

目录

- 🇮🇹 LFM2-VL 模型详解 —— 面向边缘设备的高效视觉语言理解
 - 目录
 - 🧠 引言：为何关注边缘级视觉语言模型？
 - ✨ LFM2-VL 的核心创新
 - 🏗️ 模型结构设计
 - 语言模型骨干 (LFM2 Backbone)
 - 视觉编码器 (Vision Encoder)
 - 多模态连接器与融合机制
 - 📖 训练流程设计
 - ⚡ 推理效率与灵活策略
 - 📍 典型应用场景举例
 - 🧠 思考与未来方向
 - 📄 参考资料

🧠 引言：为何关注边缘级视觉语言模型？

随着 **AI 模型从数据中心向端侧部署迁移**，对视觉 + 文本融合的多模态模型提出了新的挑战：

- **低延迟**：终端设备需要快速响应视觉指令，尤其是拍照问答、AR/VR 等场景。
- **低资源占用**：内存与能耗限制较严格，传统大模型不适合直接部署。
- **灵活推理**：支持不同分辨率图像与指令类型，自适应推理成本。

LFM2-VL 正是在此背景下，继承 LFM2 基础模型设计并扩展至视觉语言任务的高效模型。**笔者认为，LFM2-VL模型出色的能效比很大程度上得益于base模型面向异构计算单元的NAS，使得其能够击败基于相似基础模块构建的诸多主流模型。**

关注VLM发展的同学，是否有注意到一个现象–主流VLM在25年整体模型参数规模(moe模型指激活参数)整体趋势是在缩减的。这个趋势与上一个十年AI发展趋势是高度近似的，体现出一条AI发展的游戏规则–**前期重精度指标，中后期重能效优化与应用落地。**

🌟 LFM2-VL 的核心创新

创新点	核心价值
基于 LFM2 架构延伸的多模态骨干	继承语义理解优势，带来高效视觉语言理解能力。
灵活处理图像分辨率与不规则大小	不需要强制上采样，可动态分割大图，实现更好的视觉 token 管理。
用户可调推理速度与质量平衡	在推理时可调整最大图像 token 设置，实现质量与速度的权衡。
高效视觉特征压缩	PixelUnshuffle 结合轻量 MLP 降低图像 token 数量，提高效率。

创新点是不是有点眼熟？轻量级VLM的核心创新点大差不差。

🏗️ 模型结构设计

下面我们看一下 **LFM2-VL** 的整体架构及设计思路。




图1. LFM2-VL 模型架构

语言模型骨干（LFM2 Backbone）

- **LFM2-VL** 的语言部分直接基于 **LFM2 语言骨干**，因此继承了其在 **边缘设备上的高效性、长上下文支持（32K tokens）和推理速度优化** 的优势。
- 这一骨干使用了 **短卷积与分组查询注意力（GQA）混合架构**，在保持语义表达能力的同时显著降低 CPU 推理延迟。

分组查询注意力(GQA)可参阅前序文章(大模型 Attention 优化演进：从 MHA 到 MLA 的 QKV 结构全景解析)

这里，贴两组有趣的LLM性能评估结果：

Benchmark	LFM2-350M	LFM2-700M	LFM2-1.2B	Qwen3-0.6B	Llama-3.2-1B	Gemma-3-1B	Qwen3-1.7B
# Total Params	0.35B	0.70B	1.2B	0.6B	1.2B	1B	1.7B
# Trained Tokens	11T	11T	11T	36T	9T	2T	36T
Knowledge							
MMLU	43.43	49.90	55.23	44.93	46.60	40.08	59.11
MMLU-Pro	15.85	18.65	19.71	27.02	19.37	13.72	43.04
GPQA	27.46	28.48	31.47	22.14	28.84	21.07	27.72
Instruction Following							
IFEval	65.12	72.23	74.89	64.24	52.39	62.90	73.98
IFBench	16.41	20.56	20.70	19.75	16.86	17.72	21.27
Multi-IF	32.85	40.92	45.28	45.13	29.43	44.49	56.28
Mathematical Reasoning							
GSM8K	30.10	46.40	58.30	36.47	35.71	59.59	51.40
GSMPlus	22.16	29.99	36.09	9.10	18.57	40.16	29.62
MATH 500	24.20	31.80	42.40	48.60	25.00	43.40	70.00
MATH Lvl 5	5.79	11.27	18.61	19.43	14.20	14.64	36.99
Multilingual							
MMMLU	37.99	43.28	46.73	30.84	38.15	34.43	46.51
MGSM	29.52	45.36	55.04	41.28	29.12	43.60	66.56

图2. LFM2与同量级LLM(2B以下)性能评估结果

Benchmark	LFM2-8B-A1B	LFM2-2.6B	Llama-3.2-3B	SmolLM3-3B	Gemma-3-4B	Qwen3-4B	Granite-4.0-H
# Total Params	8.3B	2.6B	3.2B	3.1B	4B	4B	7B
# Active Params	1.5B	2.6B	3.2B	3.1B	4B	4B	1B
# Trained Tokens	13T	11T	9T	11T	4T	36T	15T
Knowledge							
MMLU	64.84	64.42	60.35	59.84	58.35	72.25	66.79
MMLU-Pro	37.42	25.96	22.25	23.90	34.76	52.31	32.03
GPQA	29.29	26.57	30.60	26.31	29.51	34.85	26.46
Instruction Following							
IFEval	77.58	79.56	71.43	72.44	76.85	85.62	81.06
IFBench	25.85	22.19	20.78	17.93	23.53	30.28	18.37
Multi-IF	58.19	60.26	50.91	58.86	66.61	75.54	52.99
Mathematical Reasoning							
GSM8K	84.38	82.41	75.21	81.12	89.92	68.46	82.64
GSMPlus	64.76	60.75	38.68	58.91	68.38	56.16	59.14
MATH 500	74.20	63.60	41.20	73.60	73.20	85.60	58.20
MATH Lvl 5	62.38	54.38	24.06	51.93	52.18	73.62	36.11
Multilingual							
MMMLU	55.26	55.39	47.92	50.02	50.14	60.67	56.13
MGSM	72.40	74.32	61.68	68.72	87.28	81.76	73.68

图3. LFM2与同量级LLM(2B-8B)性能评估结果

通过上述两组数据，笔者观察到2个现象：

1. 尽管训练tokens规模远小于Qwen3等LLM，LFM2与同量级LLM打得有来有回，略强于后者。
2. 受限於模型参数量，Knowledge相关测试集上，尺寸小/训练tokens少的模型表现差，但其他任务上互有胜负和反超的。

这两个现象反映了LFM2模型的先进性，和当下国内外模型发展不均衡的现状。

视觉编码器（Vision Encoder）

对于视觉输入部分，LFM2-VL 使用：

SigLIP2 NaFlex 视觉编码器

- 提供从图像到视觉 token 的高效映射。
- 支持原生分辨率到 **512×512 图像处理**，避免高成本上采样。

有两种视觉编码器配置：

模型 / Variant	Vision Encoder 类型
LFM2-VL-450M	SigLIP2 NaFlex base（参数量~86M）
LFM2-VL-1.6B	SigLIP2 NaFlex shape-optimized（参数量~400M）

受限于参数量与表征能力，SigLIP2 NaFlex base在25年推出后出现频次很低。但是**LFM系列模型中，该vision encoder表现称得上惊艳。**

多模态连接器与融合机制

为了将图像 token 和语言 token 有效融合，LFM2-VL 设计了：

- **PixelUnshuffle + MLP Connect(连接器)**：
将图像映射为更少、更高质量的视觉 tokens；
- **动态图像切片（Tiling）策略**：
处理大图像时将其分割为多个 512×512 patch，同时加入缩略图辅助全局理解；
- 两者组合实现了既**保持视觉细节**又**控制模型负载**的平衡。

PixelUnshuffle，已经是VLM(理解与生成)、具身、AV(视听)等多模态核心领域的标配工具，核心价值在于“高效下采样 + 局部信息保留”，完美适配多模态融合对“精度与效率平衡”的需求。

传统Tiling模块存在的一个核心痛点是-仅用切片会导致 "全局语义丢失"，模型无法把握图像整体布局和物体间空间关系。添加全局缩略图能够显式增强全局感知能力(提供图像整体结构，防止局部切线信息碎片化)。



训练流程设计

LFM2-VL 的训练继承了 LFM2 的训练设计思路，并加上多模态图像数据：

建模流程分为3个阶梯训练阶段和1个模型合并阶段：

1. Connector Pre-training

- LLM backbone和视觉编码器冻结，训练vision embeddings到LLM embedding空间Connector，
- 该步骤选用高学习率(可学习参数量少)，小context length(2048)。

2. 基于 LFM2 Backbone 的 Joint Mid-Training

- 初期用语文本与图像联合训练。文本占比大（例如 95% 文本/5% 图像）。
- 随后逐步提升图像比例，使模型逐步适应多模态理解。
- 作者发现这样的训练数据比例过度，可以替代Connector pretraining，所以很可能是做过消融后得到的结论。

3. 监督微调阶段（SFT）

- 重点加强图像理解任务效果，如问答、描述和 OCR 等。
- 使用大规模 **公开视觉语言数据集** 和 **内部合成数据集** 组合训练。

4. Checkpoint Selection and Merging

- 作者在训练阶段通过设置不同超参、训练数据比例等，获取了很多candidate models。
- 通过全面评估candidate models在不同任务和数据集上的表现选取了一系列最优模型。
- 通过现行融合的手段组合(包含model soup, task arithmetic, TIES-Merging, DARE, and DELLA)，得到最终模型。

结束了吗？是的，笔者跟LFM团队确认过**-VL版本模型无RL后训练阶段**。

所以，LFM团队的VL系列更适合静态感知任务，即该团队未面向推理任务定向优化，这个策略是业内比较罕见的。看一下VL版本的实测表现：

Benchmark	LFM2-VL-450M	LFM2-VL-1.6B	SmolVLM2-500M	InternVL3.5-1B
# Total Params	0.45B	1.6B	0.5B	1.1B
General (vision)				
MMStar	40.87	49.87	37.73	50.27
MMBench (dev)	55.76	69.16	51.29	70.79
RealWorldQA	52.03	65.75	51.37	57.12
MME	1,230	1,757	1,456	1,894
SEEDBench	63.62	72.00	60.34	72.67
POPE	83.68	87.17	85.83	86.30
Capability-focused (vision)				
MMMU	34.44	39.67	33.89	41.89
MathVista	45.30	51.70	34.50	53.10
BLINK	42.61	44.50	40.45	44.19
InfoVQA (val)	44.56	58.35	24.64	60.99
OCRBench	657	729	562	790
MM-IFEval	33.09	46.35	11.56	36.17

图4. LFM2-VL与同量级VLM(2B以下)性能评估结果

Benchmark	LFM2-VL-3B	SmolVLM2-2.2B	InternVL3.5-2B	Qwen3-VL-2B	Qwen2.5-VL-3B
# Total Params	3.0B	2.2B	2.3B	2.1B	3.75B
General (vision)					
MMStar	57.73	46.00	57.67	49.00	56.13
MMBench (dev)	79.81	69.24	78.18	77.58	80.41
RealWorldQA	71.37	57.50	60.78	65.75	65.23
MME	2,051	1,793	2,129	2,045	2,163
SEEDBench	76.55	71.30	75.41	74.08	73.88
POPE	89.01	85.10	87.17	89.05	86.17
Capability-focused (vision)					
MMMU	45.33	41.60	51.78	45.78	51.67
MathVista	62.20	51.50	61.60	63.50	62.50
BLINK	51.03	42.30	50.97	54.87	48.97
InfoVQA (val)	67.37	37.75	69.29	71.68	76.12
OCRBench	822	725	834	864	824
MM-IFEval	51.83	19.42	47.31	51.35	38.62
Multilingual (vision)					
MMBench (dev)	75.84	44.07	70.03	69.52	74.33
MMMB	81.52	57.82	75.86	74.11	77.60
Knowledge (language)					
MMLU	62.70	26.89	60.89	59.87	64.92
MMMLU	53.37	32.16	49.32	42.20	54.23

图5. LFM2-VL与同量级VLM(2B-4B)性能评估结果

通过上述两组数据对照，不难得出结论：尽管训练tokens规模少于同类模型(Qwen、IntelVL等)，LFM2-VL精度普遍优于同规模VLMs。

到这里，不少同学有疑问，明明是打得互有胜负，怎么就前者优于后者？

笔者提醒2个论据，下个章节还有惊喜：

1. LFM2-VL只有SFT，没有上RL。

benchmark中的其他VLMs普遍有做RL post train，RL相比SFT普遍有1个点以上的提升(可参考前序文章 InternVL3.5深度解读：开源多模态模型的通用性、推理与效率三重突破)，而LFM2-VL没有用RL；

2.LFM训练tokens更少。

无论LLMs还是VLMs，LFM系列训练tokens都小于同量级VLMs。

所以，如果只比相近trained tokens下训练得到的SFT model，差距会有多大？

推理效率与灵活策略

为了适配端侧与服务端不同环境，LFM2-VL 支持：

◆ 推理时可调精度/速度权衡

- 用户可设定 **最大图像 token 数量** 和 **Patch 数量**
- 提高图像 token 数 → 更高质量 → 适用于高端设备
- 降低图像 token 数 → 更快推理 → 适用于低算力设备

这块与Qwen、InternVL等系列做法类似。

下面重点来了，贴一组**LFM官网模型推理能效对照**结果：




图6. LFM2-VL与同量级VLM推理速度对照(caption任务)




图7. LFM2-VL与同量级VLM推理内(显)存占用对照(caption任务)

作为衡量模型能效的核心指标，推理速度和内(显)存占用层面，LFM2-VL对同量级VLMs存在碾压优势。

注：LFM2-VL发布时，Qwen3-vl还没发布，所以部分对照结果不完整，不过不影响结论。

📌 典型应用场景举例

场景	说明
🖼️ 图像描述	给定一张用户拍摄的图像，输出文字详细描述。
? 图像问答	回答用户关于图像内容的问题。
📄 OCR 文字识别	识别图像中打印或手写文字。
🌐 多模态助理	在对话系统中结合视觉与文本指令执行任务。

🧠 思考与未来方向

LFM2-VL 提出了 **兼顾效率与视觉语言能力的端侧多模态方案**。其关键思想包括：

- ✓ **硬件意识设计**：不仅优化准确性，更优化实际推理延迟。
- ✓ **Token 高效化机制**：避免视觉 token 过多导致的计算爆炸。
- ✓ **灵活训练与推理流程**：可以根据场景需求调节质量与速度。

未来可以关注：

- **更大视觉上下文能力（高分辨率图像）**
- **跨模态长期记忆与检索增强**
- **端侧本地训练与增量学习**

📖 参考资料

- *LFM2 Technical Report*, arXiv:2511.23404 — LFM2 主论文，包含 LFM2-VL 描述。
- **LFM2-VL 官方模型博客**（Liquid AI, <https://www.liquid.ai/blog/lfm2-vl-efficient-vision-language-models>） — 包含模型架构与训练细节。
- Hugging Face 模型卡（LFM2-VL-1.6B, <https://huggingface.co/LiquidAI/LFM2-VL-1.6B>） — 实际配置与推理说明。

作者提示: 个人观点, 仅供参考

修改于2025年12月15日