



华 映 资 本

## LFM2 技术报告图解

2026 年 3 月



## 核心要点

- 开篇概括： LFM2 是什么，以及为何强调边缘设备部署。
- 图 1- 图 2： 模型家族全景与混合架构设计。
- 图 3- 图 6： 后训练流程与视觉效率 - 精度权衡。
- 图 7- 图 9： 音频与检索扩展，以及吞吐表现。
- 最后总结： 从论文证据到落地选型建议。

图 1 解读： LFM2 Portfolio 全景图

从“基础模型”到“多模态与检索”形成产品化阶梯



### 核心要点


- 按参数规模覆盖 350M 到 8.3B （ 1.5B active ），形成清晰选型区间。
- 右侧结构展示从 backbone 到多模态 / 检索再到 Nanos 的扩展路径。
- 关键信号是“统一底座多分支”，而非每个任务单独训练一套模型。
- 对边缘侧价值在于：可按设备预算和场景快速匹配合适模型。

图 2 解读： LFM2 混合架构设计

短卷积主干 + 少量 GQA + 可选 MoE，兼顾速度与质量

### 核心要点

- ◆ 主体层采用 **gated short convolution**，显著降低 CPU 延迟与内存开销。
- ◆ 少量 **GQA** 层负责长程依赖，避免纯局部算子带来的信息损失。
- ◆ **MoE** 版本总参 8.3B、激活约 1.5B，实现“高质量 + 低激活成本”。
- ◆ 密集版与 **MoE** 共享骨架，体现了同架构下的分层性能策略。



开篇概括：这篇论文在回答什么问题

目标是在端侧预算约束下，同时优化质量、速度与内存

#### 核心要点

- ◆ 研究对象： LFM2 系列（ LLM、 VLM、 Audio、 CoIBERT 检索 ）统一技术底座。
- ◆ 核心方法： 硬件在环架构搜索 + 分阶段训练配方 + 面向部署的评测。
- ◆ 关键承诺： 不仅追求榜单分数，更强调可部署性与可复用性。
- ◆ 阅读重点： 论文用 9 张主图把 “设计—训练—性能—扩展” 串成闭环。

## 逐图讲解方法：每张图看四件事


图意 → 关键数据 → 工程含义 → 适用边界

### 核心要点

- ◆ 先看图回答的核心问题，再定位横轴 / 纵轴与对照关系。
- ◆ 提取能指导选型的结论：何时提速、何时降本、何时保精度。
- ◆ 不只看“最好点”，更看不同预算下的整条可行前沿。
- ◆ 每张图都给出一条可执行建议，便于直接迁移到项目评估。

图 3 解读：三阶段后训练流水线

SFT → 偏好对齐 → 模型合并，目标是能力与稳健性兼得



#### 核心要点

- Stage 1 用大规模 SFT 建立通用对话、指令跟随与任务基础能力。
- Stage 2 进行偏好对齐，减少回答风格偏移并提升可用性。
- Stage 3 通过模型合并提高跨任务鲁棒性，降低单 checkpoint 偶然性。
- ♦ 工程启示：小模型能力提升依赖完整配方，而非单一训练技巧。



图 4 解读：质量 - 吞吐 Pareto 前沿

在端侧实测中， LFM2 点位整体位于更优的右上区域

### 核心要点

- ◆ 横轴为 prefill/decode 吞吐，纵轴为平均评测得分，右上代表更优权衡。
- LFM2 多个尺寸形成连续前沿，说明不同预算下都能找到高性价比点。
- 2.6B 与 8B-A1B 在高质量区仍保持高吞吐，体现架构效率优势。
- ◆ 实践建议：先定延迟预算，再沿 Pareto 前沿挑选分数最高模型。








图 5 解读： LFM2-VL 多模态结构

SigLIP2 编码器 + PixelUnshuffle 连接器 + LFM2 语言主干




### 核心要点

- ◆ 小图走原生分辨率路径，大图走动态切片路径，再统一映射到语言空间。
- PixelUnshuffle + MLP 先压缩视觉 token，再进行跨模态对齐。
- 450M 与 1.6B 共用设计思想，主要区别在编码器容量与整体规模。
- ◆ 这张图回答“为何能端侧跑 VLM”：先控 token 成本，再做信息融合。

图 6 解读：视觉 token 预算与精度曲线

通过调节 token 上限，在“质量 - 延迟”之间实现连续折中




### 核心要点

- ◆ 横轴近似表示延迟成本，纵轴是多类视觉基准表现。
- ◆ 通用视觉理解在低预算下下降较缓，压缩容忍度更高。
- ◆ 高分辨率细节任务下降更明显，表明其对 token 数更敏感。
- ◆ 部署建议：默认低预算运行，遇到细粒度场景再按需升档。

图 7 解读： LFM2-Audio 端到端语音架构

统一解码主干同时处理文本与语音 token，形成闭环系统



### 核心要点

- ◆ 左图展示文本与音频 token 在单序列中联合建模。
- ◆ 右图展示离散语音码生成与声码器还原的输出路径。
- ◆ 统一架构减少多模块拼接复杂度，提升系统稳定性与维护性。
- ◆ 落地价值是低延迟语音助手：ASR、对话、TTS 可共用一套底座。

## 图 8 解读： LFM2-CoBERT 多语言检索效果

在 NanoBEIR 上，多语言 NDCG@10 展现了稳健跨语种能力

### 核心要点

- ◆ 英语、德语、法语、西语等语言表现较强，整体曲线较平稳。
- ◆ 低资源语言有回落但仍保持可用，体现较好的跨语言泛化。
- ◆ 结果表明预训练阶段的多语表征被有效继承到检索任务。
- ◆ 工程意义：可先用统一模型全球上线，再按重点语言做增量优化。





图 9 解读： H100 批量编码吞吐对比

批量 =1 时两者都约 60 qps，说明低并发下瓶颈主要在启动与访存，差距有限。

批量提升到 32/64 后， LFM2-ColBERT 达到约 1350/1420 qps，持续领先对比模型约 3-4%。



尽管参数量约为对比模型的 2.37 倍，吞吐仍接近甚至略优，说明实现与并行效率较强；对高并发检索服务更友好。

边缘优先设计 + 模块化扩展 + 可调推理成本

### 核心要点

- ◆ 图 1- 图 2 说明：统一架构可覆盖 LLM/VLM/Audio/ 检索多条产品线。
- ◆ 图 3 说明：能力提升依赖系统化训练流程，而非单点技巧。
- ◆ 图 4/ 图 6/ 图 9 共同说明：质量、延迟、成本之间可做量化折中。
- ◆ 图 5/ 图 7/ 图 8 说明：多模态与多语言能力可在端侧约束下保持竞争力。
- ◆ 落地建议：先按场景选模态，再用模型规模与 token 预算两级调参。

LFM2 证明了“面向端侧的小模型”也能实现强能力与高效率兼顾

### 核心要点

- ◆ 论文贡献不只在单项指标，而在于给出可部署、可复用的完整方法论。
- ◆ 对视觉任务， LFM2-VL 通过 token 预算机制提供了可控的延迟 - 精度调节。
- ◆ 对系统设计，统一底座有利于降低多模态产品的工程复杂度。
- ◆ 结论：边缘 AI 的关键不再是“参数更大”，而是“效率与能力协同优化”。