

MERIDIAN

华 映 资 本

华映资本

2026 年 2 月




核心要点

- 第一部分：论文主要创新点（研究范式、受控实验与预测方程）。
- 第二部分：论文主要发现（何时多智能体增益，何时显著退化）。
- 第三部分：论文主要贡献（理论贡献、方法贡献、工程价值）。
- 第四部分：按原文图 1 到图 6 逐页解读证据与机制。
- 第五部分：给出可部署的架构选择建议与结论讨论。

图 1 解读：能力增长会放大协同收益，但并非无条件

核心在于严谨定义、受控比较与可外推的定量模型



核心要点

- ◆ 三大模型族总体都随能力提升而上升，说明底座能力仍是首要驱动因子。
- ◆ 同等能力下，Centralized/Hybrid 常优于 SAS，说明协调机制可放大能力红利。
- ◆ 增益幅度并不恒定，局部区间出现回落，反映协调成本会抵消部分收益。
- ◆ 管理含义：应同步优化“模型能力 × 协调拓扑”，不能只做模型升级。

图 2 解读：任务结构决定 MAS 是增益还是退化

同一套架构在不同基准上的表现方向可以完全相反

核心要点

- Finance-Agent 中 MAS 可达约 +57% 到 +81%，核心原因是任务可并行分解。
- PlanCraft 中 MAS 全面退化（约 -39% 到 -70%），因为顺序依赖强且状态耦合高。
- BrowseComp 和 Workbench 介于中间，体现“部分可分解、部分受开销制约”的混合态。
- ◆ 关键判断不是任务难度本身，而是可分解性、工具负载与序列依赖的组合。





图 3 解读：成本 - 性能权衡具有模型族差异

核心问题：性能增益是否值得额外协调成本？




核心要点

- ◆ 横轴成本、纵轴性能，揭示“最高性能点”与“最优性价比点”往往不一致。
- OpenAI 族在 Centralized/Hybrid 上增益更明显，但伴随更高成本。
- Google 族较早出现收益平台期，提示轻量协调场景存在边际收益上限。
- ◆ 工程决策应先设预算约束，再在可行架构集合内优化性能。

图 4 解读：异构编队可能优于同构高配

核心问题：是否必须“所有角色都用最强模型”？




核心要点

- ◆ 该图比较了不同模型能力组合在 Centralized 与 Decentralized 中的表现差异。
- ◆ 部分家族中，“高能力子代理 + 相对弱编排者”可优于全高配同构方案。
- ◆ 说明中心节点的价值在于协同组织与信息筛选，而不只是“参数最大”。
- ◆ 异构编队可提高成本效率，但必须控制角色漂移与通信噪声。

图 5 解读：代理数量扩展存在可观测峰值

核心问题：n-agent 扩展是否单调提升？



核心要点


- ◆ 两条曲线都呈“先升后降”，证明代理数增加并非单调增益。
- Gemini-2.0 Flash 在约 7 代理附近接近峰值，之后开始退化。
- Gemini-2.5 Pro 峰值更早，意味着强模型更早进入“协调收益递减区”。
- ◆ 部署上应将代理数视作超参数在线搜索，而非固定加到最大。

图 6 解读：跨基准缩放规律不统一

核心问题：不同模型族在不同任务上的协同趋势是否一致？

核心要点

- ◆ 结构化任务中（如 Finance ），协同放大更明显。
- ◆ 不同模型族对协调机制敏感度不同，说明“架构选择”具有供应商依赖性。
- ◆ 该图与前文共同指向：最佳拓扑是任务条件化选择，而非通用默认配置。



P：被预测的代理系统任务性能（如成功率 / 准确率），是方程左边的因变量。

I（Intelligence Index）：基础大模型的“智力指数”，是一个综合能力指标，整合了推理、知识、数学、代码、指令跟随、长上下文推理和代理式工作流等多套基准的表现。

$$\begin{aligned} P = & \beta_0 + \beta_1(I - \bar{I}) + \beta_2(I - \bar{I})^2 + \beta_3 \log(1 + T) + \beta_4 \log(1 + n_a) \\ & + \beta_5 \log(1 + O\%) + \beta_6 c + \beta_7 R + \beta_8 E_c + \beta_9 \log(1 + A_e) \\ & + \beta_{10} P_{SA} + \beta_{11}(I \times E_c) + \beta_{12}(A_e \times P_{SA}) \\ & + \beta_{13}(O\% \times T) + \beta_{14}(R \times n_a) + \beta_{15}(c \times I) \\ & + \beta_{16}(E_c \times T) + \beta_{17}(P_{SA} \times \log(1 + n_a)) \\ & + \beta_{18}(I \times \log(1 + T)) + \beta_{19}(A_e \times T) + \varepsilon, \end{aligned}$$

在 N=180 个不同“模型 × 架构 × 任务”的配置上，拟合了这个“Scaling Law”模型，用来描述代理系统性能 P 如何由模型能力、系统配置、任务属性和协调指标共同决定，本质上是一个回归方程。

可执行的三步法：先判定，再选型，再优化

核心要点

- ♦ 第一步，先测 SAS 基线：若已接近或超过 45%，应谨慎引入高开销 MAS。
- ♦ 第二步，看任务可分解性：可并行任务优先 Centralized/Decentralized；强顺序任务优先 SAS。
- ♦ 第三步，做预算约束搜索：同步监控 overhead、efficiency、error amplification。
- ♦ 目标不是“更多代理”，而是“在约束下选到最匹配的协调结构”。

这篇论文把多智能体系统从经验工程推进到可验证的定量科学

核心要点

- ◆ 主要创新: 提出 **Agentic** 评估定义与受控实验框架, 建立统一比较基准。
- ◆ 主要发现: **MAS** 收益具有强条件性, 受任务结构、工具负载和协调拓扑共同决定。
- ◆ 主要贡献: 给出可预测的缩放方程与可操作的架构选择规则。
- ◆ 实践建议: 先小规模验证, 再按任务特征和预算做渐进式多代理扩展。