

扩散模型成最快深度思考！告别自回归每秒1009个tokens，英伟达微软都投了


关注前沿科技 量子位 2026年2月25日 17:51

一水 发自 凹非寺
量子位 | 公众号 QbitAI

首个会深度思考的扩散模型来了！


抛弃自回归范式，一举成为世界上生成速度最快的模型。

你瞅瞅，对比之下传统自回归的“打字机模式”（按顺序一个个token往外吐）是不是就有点像乌龟了：




实际测评显示，这款名为**Mercury 2**的扩散推理LLM在英伟达GPU上可实现**1009个tokens/s**。


这个速度整整比GPT-5（mini）和Claude-4.5（haiku）这些传统模型快了5倍。




消息一出，英伟达第一时间跑来祝贺了（当然也可能是因为它投了Mercury 2背后的公司）：



一众网友也纷纷坐不住，毕竟最近很火的“龙虾们”也少不了对速度的极限追求：



还有人已经开始怀念自回归曾经的风光了（doge）。



so，Mercury 2是谁？它又是如何突破速度瓶颈的呢？

不止是快，还稳

原理其实很简单。

前面已经说了，传统自回归就像打字机一样，一次只能处理一个token，且必须按照从左到右的顺序。

但扩散模型Mercury 2的工作方式更像一位编辑——


你不是在看它打字，而是看它拿到一份草稿后，立刻拿着红笔在整页纸上同时圈改。

换言之，一次生成答案草稿再整体编辑。


这种“并行优化”机制，使得Mercury 2不需要等待前一个字的結果就能生成下一个字，因此响应速度极快，延迟不再与输出长度成正比。

最终，Mercury 2能将生成速度提升5倍以上，且速度曲线截然不同。

瞅瞅，在第三方测评中，其输出速度可谓一骑绝尘。



和市面主流的顶尖模型比，速度也是独一档的存在。



在实际体验中，Mercury 2就像官方demo演示的那样，输入问题就能立马得到响应：

02:00

而且不止是快，它在性能、价格方面都具有一定优势。

延迟低至1.7s的情况下，在GPQA（科学问答）、LCB（编程）、AIME（数学）等多个基准测试中，Mercury 2的得分普遍高于或持平于那些速度较慢的“小型/轻量级”模型（如GPT-5 Nano, Claude 4.5 Haiku）。

甚至在AIME上的得分超过了公认的“性能怪兽”Gemini 3 Flash（推理版）。


这说明Mercury 2在保持极高速度的同时，并不以牺牲智商为代价。

Model	E2E Latency (Seconds)	GPQA Diamond	LCB	SciCode	IFBench	AIME	TAU
 MERCURY 2	1.7	74	67	38	71	91	53
GPT-5 NANO (MINIMAL)	4.5	43	47	29	33	27	26
CLAUDE 4.5 HAIKU (NON-REASONING)	5.0	65	51	34	42	39	33
GEMINI 2.5 FLASH-LITE (REASONING)	7.8	71	59	29	53	69	31
GEMINI 3 FLASH (REASONING)	14.4	90	91	51	78	78	80
GEMINI 2.5 FLASH (REASONING)	15.6	79	69	39	50	57	32
GPT-5 MINI (MEDIUM)	22.8	80	69	41	71	48	71
CLAUDE 4.5 HAIKU (REASONING)	23.4	67	62	43	54	84	55

 公众号 · 量子位

它目前支持128K上下文，输入价格为每百万token 0.25美元（约合人民币1.7元），输出价格为每百万token 0.75美元（约合人民币5.2元）。

综合速度与价格，Mercury 2也保持了较高性价比。



官方表示，Mercury 2的这种速度优势改变了推理。

如今，更高的智能意味着更多的test-time计算——更长的链、更多的样本、更多的重试，而这直接以延迟和成本为代价。基于扩散的推理能够在实时延迟预算内实现推理级别的质量。

背后公司一开始就押注扩散模型

最后介绍一下Mercury 2背后的公司及团队。

它是由Inception Labs这家成立于2024年的硅谷初创公司推出的。

从一开始这家公司就力押扩散模型，其核心使命为——

用全新的、基于扩散/diffusion的生成机制替代传统的自回归Transformer模型，从根本上突破速度与成本瓶颈。

他们认为，传统自回归模型的缺陷不言自明——延迟和成本会随着token数量的增加而增加。


而扩散模型采用由粗到精的生成过程。它并非逐个提交数据，而是通过少量步骤并行迭代地细化输出。这使得在生成过程中可以进行修改，并带来截然不同的速度-成本曲线。一言以蔽之：

人工智能不应该像单向打字机那样运作，而应该更像一个编辑。

基于此，他们开始在Mercury系列中践行这一理念。

2025年2月，发布全球首个基于扩散模型的商业级语言模型——初代Mercury，一开始就把生成速度拉到传统的5倍以上，而且同一时间还推出编程助手Mercury Coder。

一年之后，升级版Mercury 2问世，在推理和多智能体日益进入主流视线的今天，带来了更多可能。



事实上，早在2019年，这家公司的**联合创始人CEO Stefano Ermon**就开始投身扩散模型的研究了。

时任斯坦福大学计算机科学教授的Stefano Ermon，很早就思忖着将扩散模型应用于内容生成。

当时主流的图像生成模型还在使用GAN（生成对抗网络），但他和团队认为结果“不够好”，于是开始尝试应用Diffusion。

而在看到Diffusion的效果不错后（后来Midjourney、DALL-E等都是用这种方法），他们开始将研究目光转向文本和代码生成。

图像由连续的像素构成，而文本由离散的token构成。之前成功的扩散模型理论（如去噪得分匹配）是建立在连续空间上的，无法直接迁移到文本。

于是在2023年，他和团队发表了一篇关键性论文《Discrete Diffusion Modeling by Estimating the Ratios of the Data Distribution》，里面介绍了一种名为Score Entropy Discrete Diffusion models（SEDD）的模型。

该模型创新性提出了“分数熵”（score entropy）这一全新损失函数，它巧妙地将连续空间的分数匹配理论扩展到了离散数据领域。

这使得扩散模型能够像理解图像一样，去理解和生成语言。

arXiv > stat > arXiv:2310.16834

Search...
Help | A

Statistics > Machine Learning

[Submitted on 25 Oct 2023 (v1), last revised 6 Jun 2024 (this version, v3)]

Discrete Diffusion Modeling by Estimating the Ratios of the Data Distribution

Aaron Lou, Chenlin Meng, Stefano Ermon

Despite their groundbreaking performance for many generative modeling tasks, diffusion models have fallen short on discrete data domains such as natural language. Crucially, standard diffusion models rely on the well-established theory of score matching, but efforts to generalize this to discrete structures have not yielded the same empirical gains. In this work, we bridge this gap by proposing score entropy, a novel loss that naturally extends score matching to discrete spaces, integrates seamlessly to build discrete diffusion models, and significantly boosts performance. Experimentally, we test our Score Entropy Discrete Diffusion models (SEDD) on standard language modeling tasks. For comparable model sizes, SEDD beats existing language diffusion paradigms (reducing perplexity by 25-75%) and is competitive with autoregressive models, in particular outperforming GPT-2. Furthermore, compared to autoregressive models, SEDD generates faithful text without requiring distribution annealing techniques like temperature scaling (around 6-8 times better generative perplexity than un-annealed GPT-2), can trade compute and quality (similar quality with 32 times fewer network evaluations), and enables controllable infilling (matching nucleus sampling quality while enabling other strategies besides left to right prompting).

Comments: ICML 2024 Oral. Code at [this URL](#)

Subjects: **Machine Learning (stat.ML)**; Computation and Language (cs.CL); Machine Learning (cs.LG)

Cite as: [arXiv:2310.16834](#) [stat.ML]

(or [arXiv:2310.16834v3](#) [stat.ML] for this version)

<https://doi.org/10.48550/arXiv.2310.16834>

 公众号 · 量子位

论文结果表明，SEDD的表现明显优于当时已有的语言模型，困惑度比未退火（未使用“动态调整温度”这个优化技巧）的GPT-2好6-8倍。

（注：后来这篇论文还获得了ICML 2024最佳论文奖）

见此，Stefano Ermon决定通过创业将技术价值放大。

于是在2024年夏天，他邀请美国加利福尼亚大学洛杉矶分校教授Aditya Grover（左）和美国康奈尔大学教授Volodymyr Kuleshov（右）加入Inception Labs。



去年11月，这家公司还宣布获得了5000万美元融资，而且投资阵容相当豪华。

除了NVentures（英伟达风投部门）、M12（微软旗下风险基金）、Menlo Ventures（领投方、知名长期风投机构）等明星机构，还不乏吴恩达、卡帕西这些AI大佬。

可以说，坚持走扩散模型路子的Inception Labs始终稳扎稳打并获得市场支持。

最后顺便一提，Mercury 2目前暂无开源计划，不过其API全面兼容OpenAI标准。

感兴趣的朋友也可亲自上手一试了。

体验地址：

<https://chat.inceptionlabs.ai/>

参考链接：

[1]<https://x.com/StefanoErmon/status/2026340720064520670?s=20>

[2]<https://www.inceptionlabs.ai/blog/introducing-mercury-2>

[3]<https://x.com/ArtificialAnlys/status/2026360497851846707>

— 欢迎AI产品从业者共建 —

📖 「AI产品知识库」是量子位智库基于长期产品库追踪和用户行为数据推出的飞书知识库，旨在成为AI行业从业者、投资者、研究者的核心信息枢纽与决策支持平台。





AI产品知识库

——量子位为AI产品从业者提供的“活地图”和“决策脑”，帮助读者省100小时信息搜集、领先1个版本知道对手动向、提前1个季度锁定红利赛道。

•  内容板块

国内AI产品库 | AI 100产品榜单 | AI 100访谈实录

| 国内AI产品数据月报 | 国内AI产品全景图

扫码进入知识库
参与共建





公众号 量子位

一键关注  点亮星标
科技前沿进展每日见



量子位

追踪人工智能新趋势，关注科技行业新突破

3741篇原创内容

公众号